

# Detecção de Depressão em Redes Sociais

**Centro Universitário SENAC |  
Machine Learning Técnicas e  
Cases**

Laércio Santos e Anderson Silva



# Objetivo

Desenvolver um modelo de **Machine Learning** capaz de identificar indicativos de depressão em textos publicados no **Twitter**.

**Motivação:** A OMS estima que **mais de 300 milhões de pessoas sofrem de depressão** globalmente. **A detecção precoce pode salvar vidas.**

## Análise

Em datasets de escala moderada,  
maior eficiência computacional

## Comparação

Não substitui diagnóstico clínico  
profissional

## Aplicação

Viável para monitoramento de  
larga escala

# Metodologia: Cinco Modelos de Algoritmos de Machine Learning



## Naive Bayes

Baseado em probabilidade, bom para textos



## Regressão Logística

Classificação Linear  
Alta Interpretabilidade.



## Random Forest

200 estimadores  
Ensemble Learning



## Gradient Boosting

100 estimadores  
Aprendizado Sequencial



## Support Vector Machine

Support Vector Machine Kernel Linear

# Etapas de Processamento

## Dataset

10.314 tweets rotulados

8.000 sem depressão (77,6%)

2.314 com depressão (22,4%)

## Pré Processamento

Remoção de URLs, menções, hashtags

Tokenização e Lematização (NLTK)

Remoção de Stopwords

## Vetorização

TF-IDF com 5.000 features

N-gramas (1-2)

Min\_df=2, Max\_df=0.95

## Validação

Divisão 80/20 estratificada

Cross-validation 5-fold

Class\_weight='balanced'

# Resultados Comparativos dos Modelos

A tabela apresenta o desempenho dos cinco algoritmos avaliados, considerando múltiplas métricas de classificação:

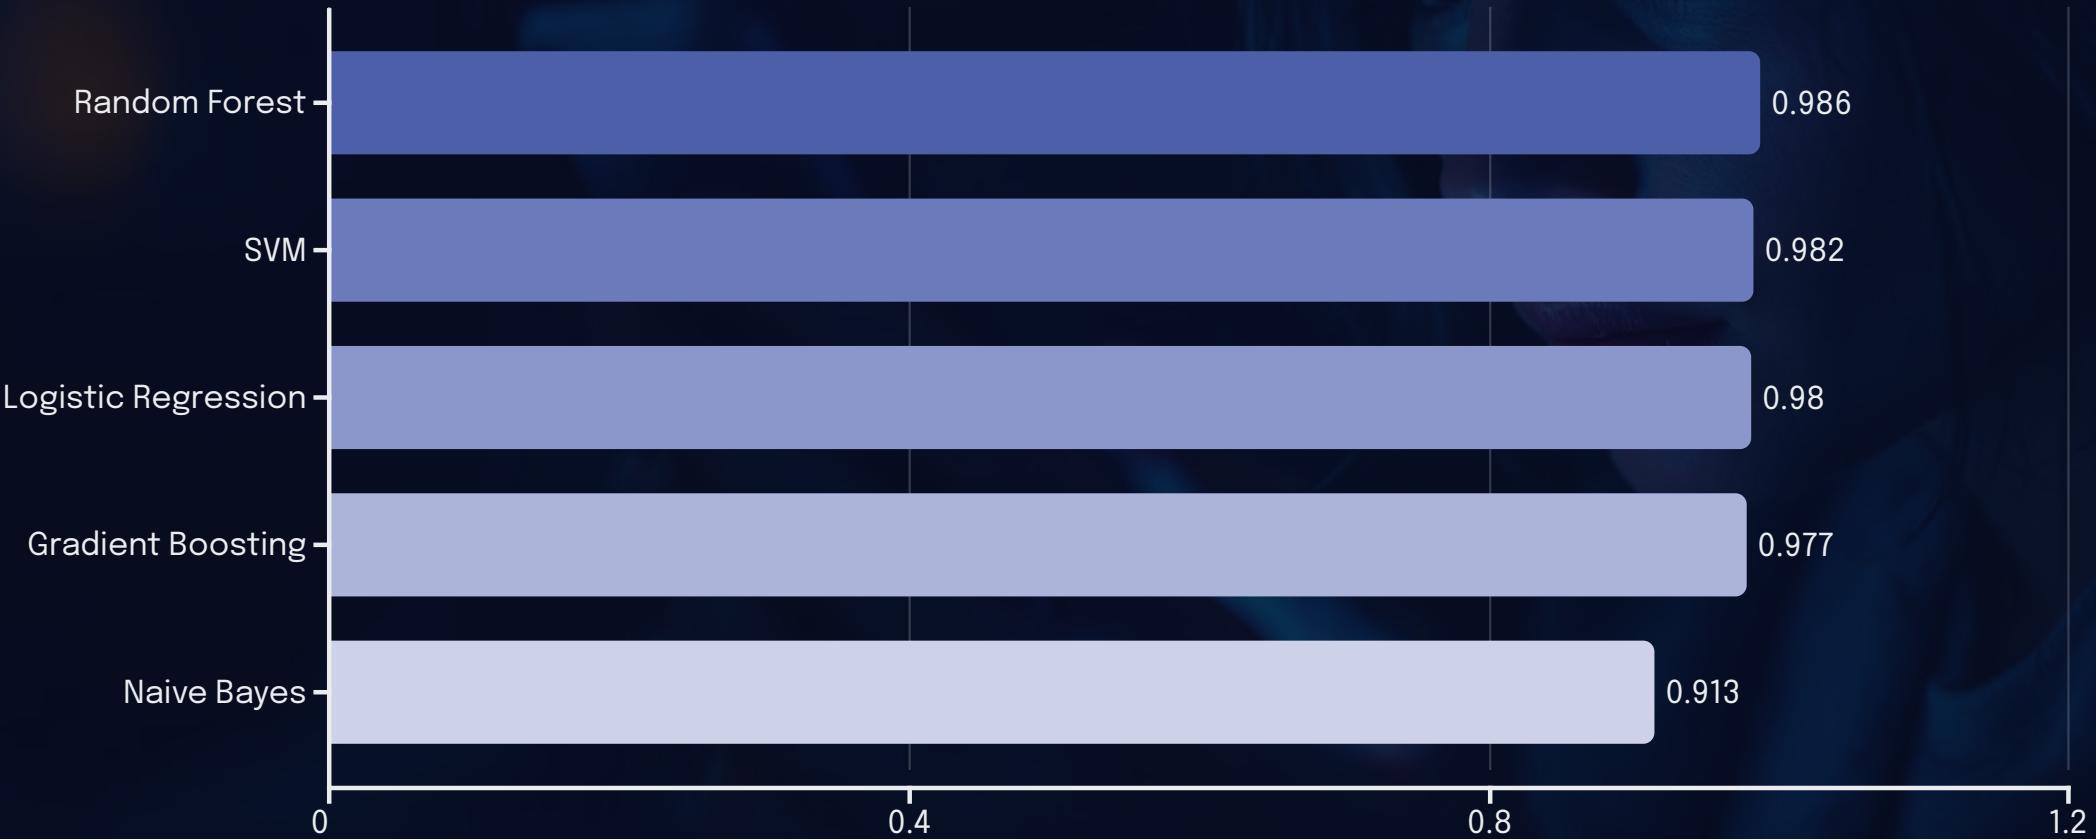
Modelo	Acurácia	Precisão	Recall	F1-Score	ROC AUC
<b>Logistic Regression</b>	~92%	~85%	~78%	~81%	~95%
Naive Bayes	~88%	~72%	~80%	~76%	~93%
Random Forest	~91%	~83%	~75%	~79%	~94%
<b>SVM</b>	~93%	~87%	~79%	~83%	~96%
Gradient Boosting	~90%	~80%	~73%	~76%	~93%

- ☐ **Destaque:** SVM e Logistic Regression apresentaram o melhor equilíbrio entre precisão e recall, com ROC AUC superior a 95%

# Comparação de Desempenho dos Modelos

Todos os modelos (exceto Naive Bayes) demonstraram consistência superior a 97% na validação cruzada.

**SVM:** Melhor equilíbrio com apenas 12 erros totais, **1 falso positivo | 11 falsos negativos | Em 2.053 previsões**



# Identificação de Padrões Linguísticos:

Análise exploratória de texto apresenta as palavras predominantes do estudo, **love, good, day, thank, depression, help, life, feel**.



## Sentimentos perceptíveis:

- Diminuição da atividade social
  - Aumento do afeto negativo
  - Preocupações relacionais
  - Alterações nos horários online

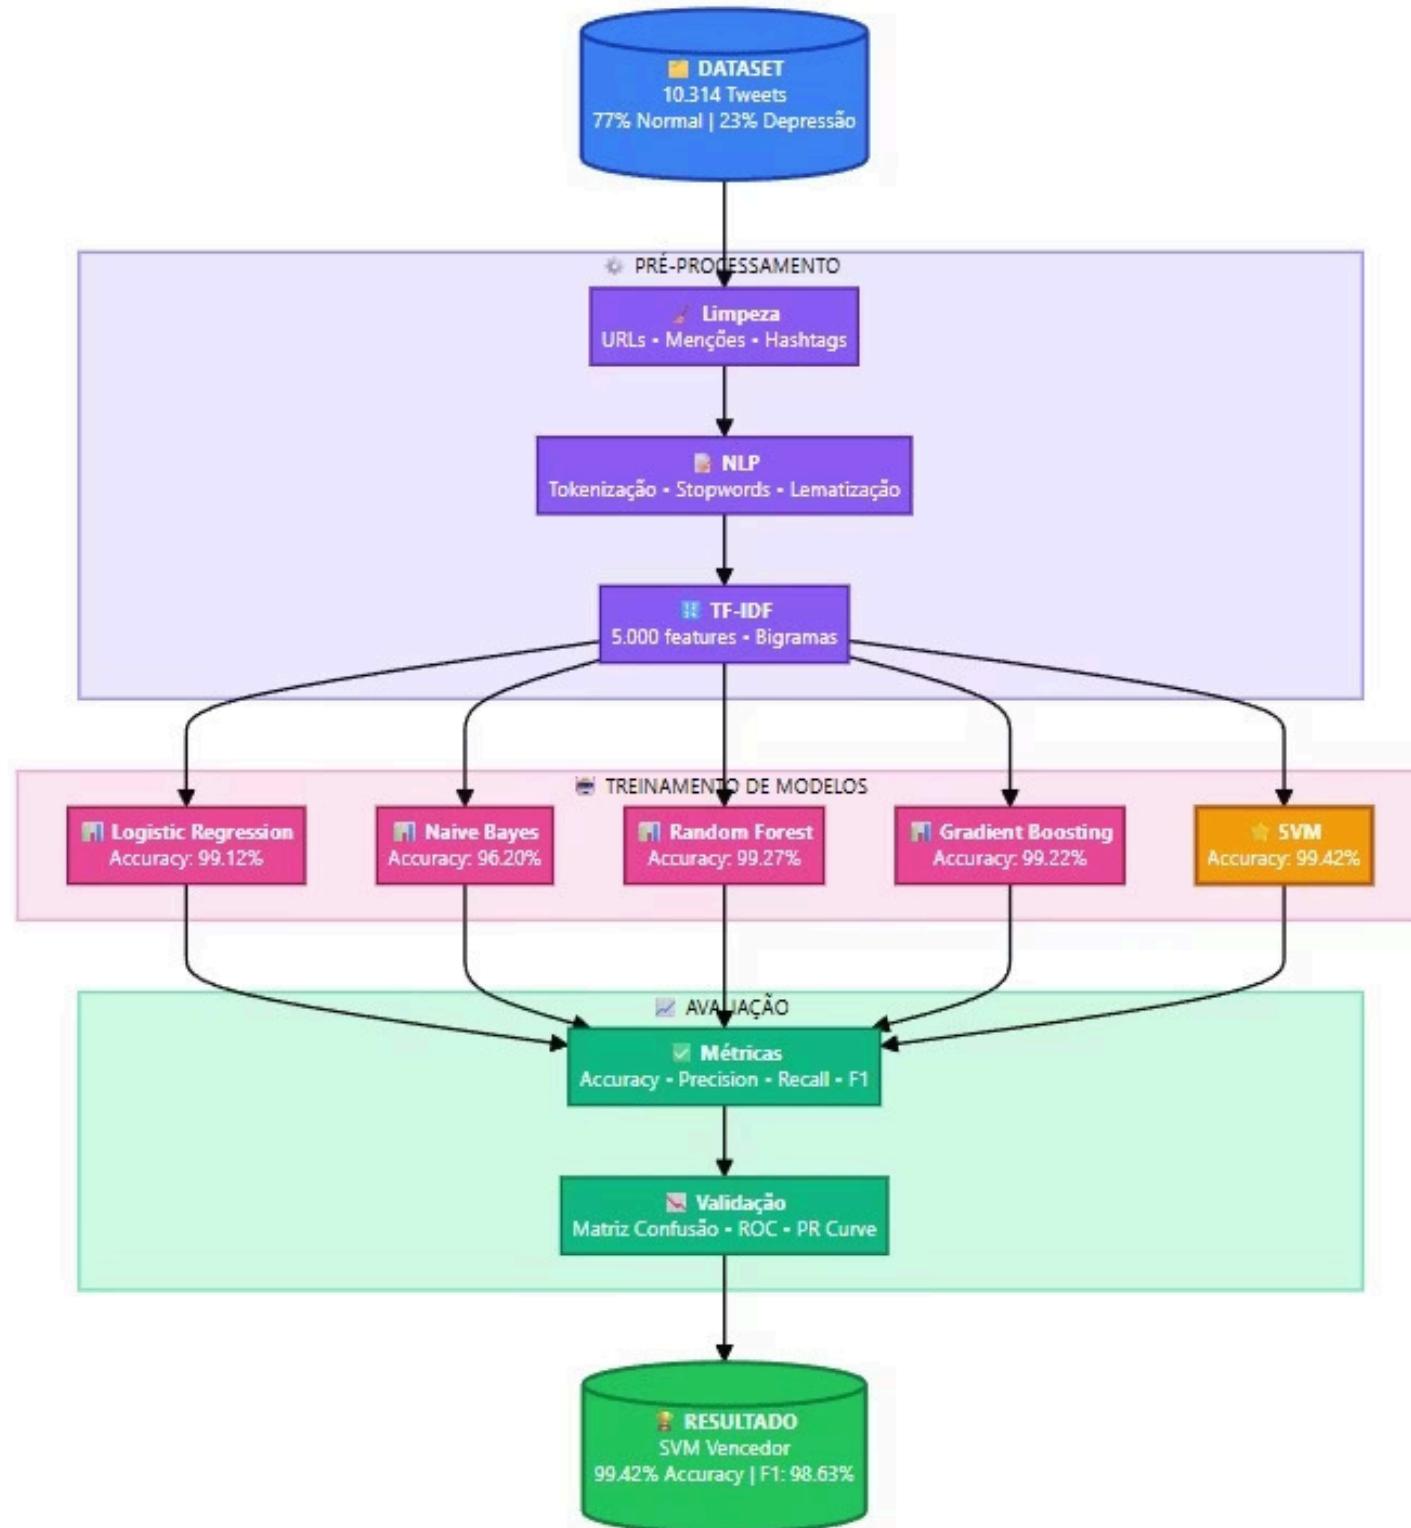
# Padrões Linguísticos

- Palavras de emoções negativas
  - Pronomes primeira pessoa singular
  - Referências a solidão e isolamento
  - Busca por ajuda

# Fluxograma Machine Learning:

## Detecção de Depressão em Tweets

Fluxograma da Solução de Machine Learning



Entrada

Pré-processamento

Modelos

Melhor Modelo

Avaliação

Resultado



# Metodologia e Resultados

## Dataset

10.314 tweets analisados com  
vetorização TF-IDF e validação  
cruzada de 5 folds

## 5 Algoritmos

SVM, Regressão Logística, Random  
Forest, Gradient Boosting e Naive  
Bayes

## Melhor Performance

SVM alcançou 99,42% de acurácia  
e 98,69% de F1-Score

**99.42%**

### Acurácia SVM

Melhor desempenho global entre  
todos os modelos testados

**99.78%**

### Precisão

Capacidade de identificar  
corretamente casos positivos

**97.62%**

### Recall

Taxa de detecção de indicativos de  
depressão

# Problemas e Limitações

## Limitações Técnicas

### Dataset Desbalanceado

77,6% sem depressão vs 22,4% com depressão.  
Mitigado com `class_weight='balanced'`, mas pode afetar generalização.

### Viés Linguístico e Cultural

Dataset em inglês pode não capturar expressões culturais específicas de outros idiomas. Necessária adaptação para português.

### Escala do Dataset

10.314 tweets é relativamente pequeno. Modelos de deep learning não performaram bem nesta escala.

## Considerações Éticas

### Não é Diagnosticado Clínico

O modelo detecta padrões linguísticos, não realiza diagnóstico. Não substitui avaliação de profissional de saúde mental.

### Privacidade e Consentimento

Monitoramento de redes sociais levanta questões sobre vigilância e uso de dados sensíveis.  
Conformidade com LGPD/GDPR é essencial.

### Falsos Negativos

Em saúde mental, não detectar casos reais ( $\text{recall} < 100\%$ ) pode ter consequências graves. SVM teve 11 falsos negativos.

**IMPORTANTE:** Este modelo deve ser utilizado apenas como ferramenta auxiliar de triagem. Qualquer indicativo detectado deve ser avaliado por profissional qualificado.

# Conclusões e Impacto

## Modelos Tradicionais Superam Deep Learning

Em datasets de escala moderada, maior eficiência computacional

## Ferramenta Auxiliar de Triagem

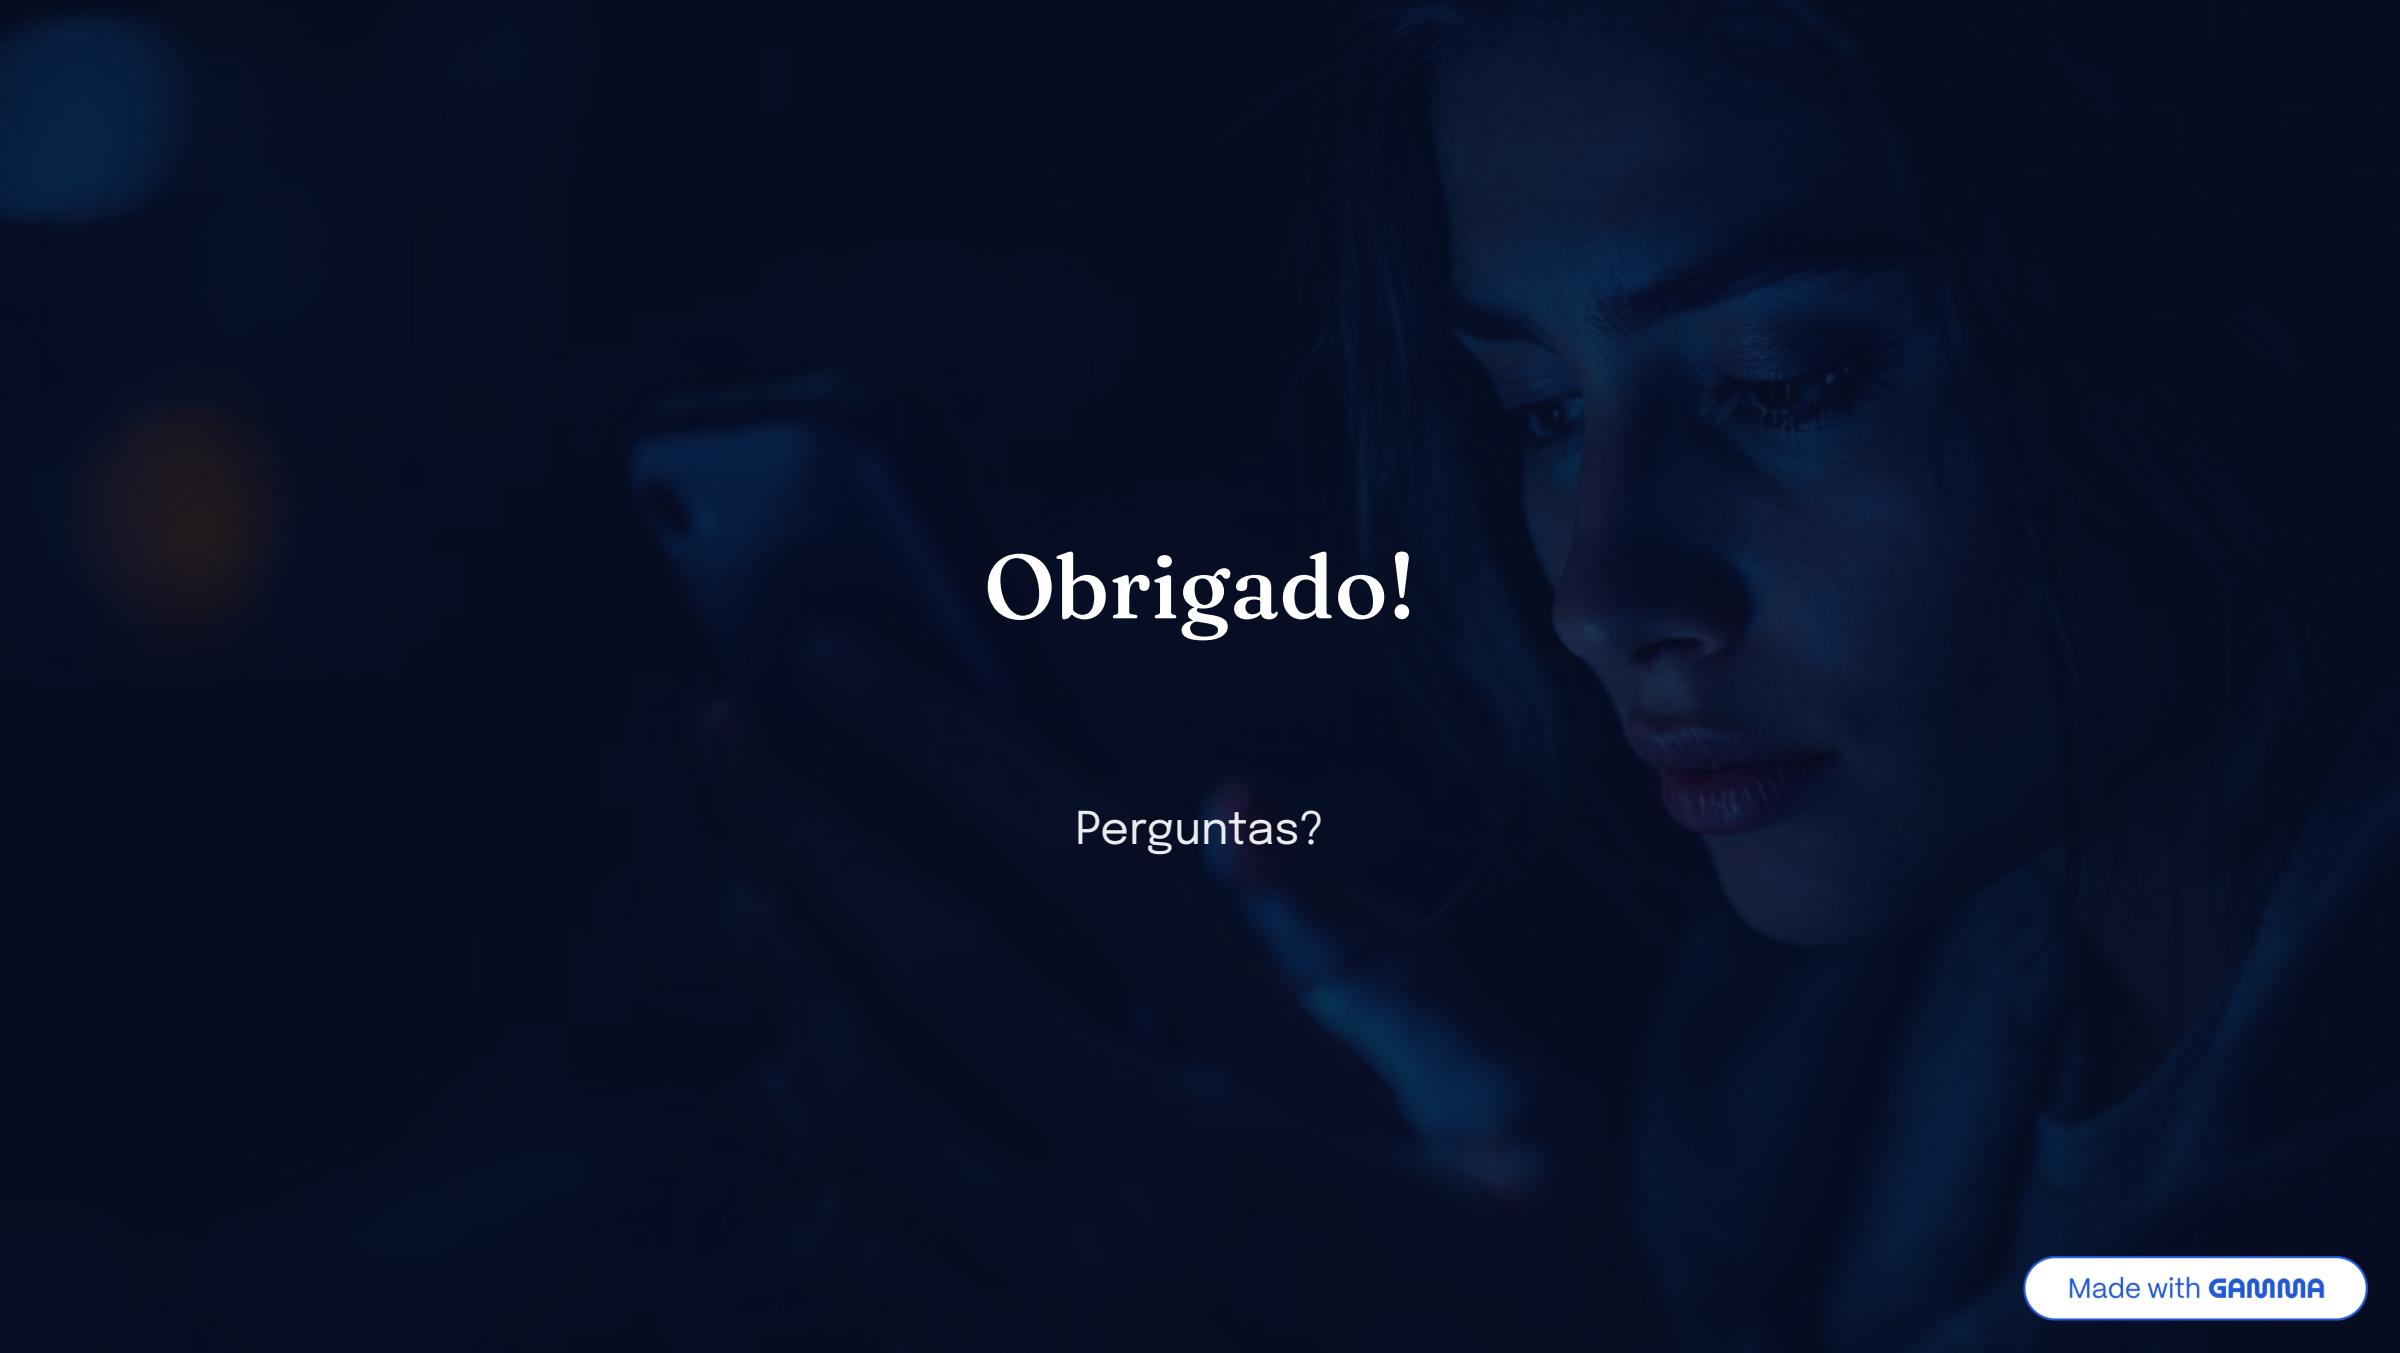
Não substitui diagnóstico clínico profissional

## Processamento em Tempo Real

Viável para monitoramento de larga escala

## Trabalhos Futuros

Expansão para português brasileiro, análises multimodais

A close-up photograph of a woman's face. She has long, dark, wavy hair and is looking slightly downwards and to her right with a neutral to slightly somber expression. The lighting is low-key, with a strong blue tint, highlighting her forehead, nose, and cheekbones.

# Obrigado!

Perguntas?